

线性判别函数习题

姓名：甘云冲

学号：2101213081

1.

$$\begin{aligned} J(\mathbf{w}) &= \frac{(P_1\mu_1 - P_2\mu_2)^2}{P_1\sigma_1^2 + P_2\sigma_2^2} \\ &= \frac{(P_1\mathbf{w}^T\mathbf{m}_1 - P_2\mathbf{w}^T\mathbf{m}_2)^2}{P_1\mathbf{w}^T\mathbf{S}_1\mathbf{w} + P_2\mathbf{w}^T\mathbf{S}_2\mathbf{w}} \\ &= \frac{\mathbf{w}^T(P_1\mathbf{m}_1 - P_2\mathbf{m}_2)(P_1\mathbf{m}_1 - P_2\mathbf{m}_2)^T\mathbf{w}}{\mathbf{w}^T(P_1\mathbf{S}_1 + P_2\mathbf{S}_2)\mathbf{w}} \end{aligned}$$

定义

$$\mathbf{S}_b^* = (P_1\mathbf{m}_1 - P_2\mathbf{m}_2)(P_1\mathbf{m}_1 - P_2\mathbf{m}_2)^T, \mathbf{S}_w^* = P_1\mathbf{S}_1 + P_2\mathbf{S}_2$$

于是有

$$J(\mathbf{w}) = \frac{\mathbf{w}^T\mathbf{S}_b^*\mathbf{w}}{\mathbf{w}^T\mathbf{S}_w^*\mathbf{w}}$$

利用Fisher线性判别结论有

$$\hat{\mathbf{w}} = \mathbf{S}_w^{*-1}(P_1\mathbf{m}_1 - P_2\mathbf{m}_2) = (P_1\mathbf{S}_1 + P_2\mathbf{S}_2)^{-1}(P_1\mathbf{m}_1 - P_2\mathbf{m}_2)$$

2.

(1)

采用反证法，假设凸包交集不为空，至少存在一点 \mathbf{z} ，有 $\mathbf{z} \in S(A) \cap S(B)$ ，于是有：

$$\mathbf{z} = \sum_{i=1}^n a_i \mathbf{x}_i = \sum_{i=1}^m b_i \mathbf{y}_i$$

由于线性可分，假设存在超平面 $\Pi: \mathbf{w}^T \mathbf{x} + b = 0$ 将A和B分开，且：

$$\mathbf{w}^T \mathbf{x}_i + b < 0 < \mathbf{w}^T \mathbf{y}_j + b$$

不妨令：

$$\epsilon_1 = \max \{ \mathbf{w}^T \mathbf{x}_i + b \mid \mathbf{x}_i \in A \} < 0 < \min \{ \mathbf{w}^T \mathbf{y}_i + b \mid \mathbf{y}_i \in B \} = \epsilon_2$$

将 \mathbf{z} 带入：

$$\begin{aligned} \mathbf{w}^T \mathbf{z} + b &= \sum_{i=0}^n a_i \mathbf{w}^T \mathbf{x}_i + b < (\epsilon_1 - b) \sum_{i=0}^n a_i + b = \epsilon_1 \\ \mathbf{w}^T \mathbf{z} + b &= \sum_{i=0}^n b_i \mathbf{w}^T \mathbf{y}_i + b > (\epsilon_2 - b) \sum_{i=0}^n b_i + b = \epsilon_2 \\ &\Rightarrow \epsilon_2 < \epsilon_1 \end{aligned}$$

矛盾，所以它们的交集为空。

(2)

由于A和B线性可分，所以SVM的解存在，不妨设在A、B侧的支持平面分别为：

$$\Pi_A: \mathbf{w}^T \mathbf{x} = p, \quad \Pi_B: \mathbf{w}^T \mathbf{x} = q$$

以及

$$\mathbf{w}^T \mathbf{x} \leq p, \forall \mathbf{x} \in A, \quad \mathbf{w}^T \mathbf{x} \geq q, \forall \mathbf{x} \in B$$

分离超平面即为：

$$\Pi: \mathbf{w}^T \mathbf{x} = \frac{p+q}{2}$$

最大间隔即等价于：

$$\max_{\mathbf{w}} \frac{q-p}{\|\mathbf{w}\|}$$

同时有等价于：

$$\min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w}\|^2 - (q - p)$$

$$s. t. \begin{cases} \mathbf{w}^T \mathbf{x} \leq p, & \mathbf{x} \in A, \\ \mathbf{w}^T \mathbf{x} \geq q, & \mathbf{x} \in B \end{cases}$$

于是拉格朗日函数为：

$$L = \frac{1}{2} \|\mathbf{w}\|^2 - (q - p) - \sum_{i=1}^n \alpha_i (p - \mathbf{w}^T \mathbf{x}_i) - \sum_{i=1}^m \beta_i (\mathbf{w}^T \mathbf{y}_i - q)$$

于是：

$$\frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} + \sum_{i=1}^n \alpha_i \mathbf{x}_i - \sum_{i=1}^m \beta_i \mathbf{y}_i$$

$$\frac{\partial L}{\partial p} = 1 - \sum_{i=1}^n \alpha_i$$

$$\frac{\partial L}{\partial q} = \sum_{i=1}^m \beta_i - 1$$

令上式都为0，则对偶优化问题变为：

$$\min_{\mathbf{w}} \frac{1}{2} \left\| \sum_{i=1}^m \beta_i \mathbf{y}_i - \sum_{i=1}^n \alpha_i \mathbf{x}_i \right\|^2$$

$$s. t. \begin{cases} \sum_{i=1}^n \alpha_i = 1, & \alpha_i \geq 0 \\ \sum_{i=1}^m \beta_i = 1, & \beta_i \geq 0 \end{cases}$$

这即为凸包 $S(A)$ 和 $S(B)$ 的距离的最近点。

3.

(1)

拉格朗日函数为：

$$L = \frac{1}{2} \|\mathbf{w}\|^2 - v\rho + \frac{1}{n} \sum_{i=1}^n \xi_i - \alpha\rho - \sum_{i=1}^n \alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - \rho + \xi_i] - \sum_{i=1}^n \beta_i \xi_i$$

于是：

$$\begin{aligned}\frac{\partial L}{\partial \mathbf{w}} &= \mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i \\ \frac{\partial L}{\partial b} &= - \sum_{i=1}^n \alpha_i y_i \\ \frac{\partial L}{\partial \rho} &= -v - \alpha + \sum_{i=1}^n \alpha_i \\ \frac{\partial L}{\partial \xi_i} &= \frac{1}{n} - \alpha_i - \beta_i\end{aligned}$$

令上式都为0，即为：

$$\begin{aligned}L &= \frac{1}{2} \|\mathbf{w}\|^2 - v\rho + \frac{1}{n} \sum_{i=1}^n \xi_i - \alpha\rho - \sum_{i=1}^n \alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - \rho + \xi_i] - \sum_{i=1}^n \beta_i \xi_i \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i y_i (\mathbf{w}^T \mathbf{x}_i + b) \\ &= \frac{1}{2} \|\mathbf{w}\|^2 - \mathbf{w}^T \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i - b \sum_{i=1}^n \alpha_i y_i \\ &= -\frac{1}{2} \|\mathbf{w}\|^2 \\ &= -\frac{1}{2} \sum_{i,j=1}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j\end{aligned}$$

对偶形式为：

$$\begin{aligned}\min_{\alpha} & \left[\frac{1}{2} \sum_{i,j=1}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j \right] \\ s.t. & \quad 0 \leq \alpha_i \leq \frac{1}{n} \quad i = 1, \dots, n \\ & \quad \sum_{i=0}^n \alpha_i y_i = 0\end{aligned}$$

(2)

对偶形式：

$$\begin{aligned} \min_{\alpha} \quad & \left[\frac{1}{2} \sum_{i,j=1}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=0}^n \alpha_i \right] \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq \frac{1}{n\hat{\rho}} \quad i = 1, \dots, n \\ & \sum_{i=0}^n \alpha_i y_i = 0 \end{aligned}$$

由于 $\hat{\rho} > 0$ ，由KKT条件 $\alpha\rho = 0 \Rightarrow \alpha = 0$ ，所以有 $v = \sum_{i=1}^n \alpha_i$ 。

所以上式的对偶形式可改为：

$$\begin{aligned} \min_{\alpha} \quad & \left[\frac{1}{2} \sum_{i,j=1}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j - v \right] \\ \text{s.t.} \quad & 0 \leq \hat{\alpha}_i \leq \frac{1}{n} \quad i = 1, \dots, n \\ & \sum_{i=0}^n \hat{\alpha}_i y_i = 0 \end{aligned}$$

其中 $\hat{\alpha}_i = \alpha_i \rho$ ， v 为常数。

$$\begin{aligned} \min_{\alpha} \quad & \left[\frac{1}{2} \sum_{i,j=1}^n y_i y_j \hat{\alpha}_i \hat{\alpha}_j \mathbf{x}_i^T \mathbf{x}_j \right] \\ \text{s.t.} \quad & 0 \leq \hat{\alpha}_i \leq \frac{1}{n} \quad i = 1, \dots, n \\ & \sum_{i=0}^n \hat{\alpha}_i y_i = 0 \end{aligned}$$

和(1)中的对偶形式相同，所以该线性支持向量机与v-SVM的分类器等价。

(3)

由KKT条件可以知道：

$$\alpha\rho = 0$$

同时有：

$$\begin{aligned} -v - \alpha + \sum_{i=1}^n \alpha_i &= 0 \\ 1 - \sum_{i=1}^n \alpha_i - \sum_{i=1}^n \beta_i &= 0 \end{aligned}$$

由于 $\beta_i \geq 0$, 有 $\sum_{i=1}^n \alpha_i < 1$ 。

所以 $v > 1 > \sum_{i=1}^n \alpha_i$:

$$\alpha = \sum_{i=1}^n \alpha_i - v \neq 0$$

一定有 $\rho = 0$ 。